




LLM internals

언어 모델의 계보와 알고리즘 진화 (2023-2026)

신정규
래블업 주식회사


2026년 5월 12일



- 2023년 2월 Llama 1 공개 이후, 오픈 웨이트 LLM이 **50종 넘게** 등장
- 골격은 모두 Decoder-only Transformer지만, 내부 구조는 갈수록 갈라지는 중
- Normalization · Attention · Positional · Activation · MoE의 변주가 여러 갈래로 늘어나는 중
- 새 모델을 볼 때 *어디서 갈라졌고 어디로 향하는지*를 알면 구조가 빨리 보임
- 이 발표에서는 시간 축(가계도)과 알고리즘 축(스레드)을 따로 보며 LLM 진화 지도를 그려봄

Part 1**시간 축으로 본 가계도****Part 2****알고리즘 변화, 주제별로 살펴보기****Part 3****종합과 서빙 시사점**

'흐름'은 엄격한 출시 순서가 아니라, 여러 모델군에서 반복된 아키텍처 패턴을 묶은 단위.
시기는 시작점을 뜻하고 서로 겹칠 수 있음




흐름	시기	주제	대표 모델
1	2023-02~	기반 정립	Llama 1/2/3, Mistral, Cohere
2	2024-02~	Gemma 변주	Gemma 1 · 2 · 3 · 3n · 4
3	2024-04~	효율화 · 소형화	Qwen 2/2.5/3, OLMo, Phi, SmolLM
4	2024~	특수화 · 지역화	StarCoder2, InternLM, GLM-4, HyperCLOVA X SEED
5	2023-12~	MoE 시대	Mixtral, DeepSeek V2/V3/V4, Qwen MoE
6	2023-12~	Beyond Transformer	Mamba 1/2, RWKV v7
7	2024-03~	Hybrid	Jamba, Nemotron-H, Nemotron 3 Nano, Qwen3 Next
8	2025-04~	신표준	Llama 4, DeepSeek V4, Qwen 3.5/3.6, Nemotron Omni

Part 1

시간 축으로 본 가계도

Llama 1(2023-02) 이후의 오픈 모델 대부분은 Llama 직계이거나, 그 골격을 살짝 바꾼 변형

- 표준 골격: Decoder-only Transformer · Pre-norm
- Llama가 정립한 4종 세트:
 - RMSNorm (Pre-norm)
 - SwiGLU activation
 - RoPE positional embedding
 - MHA → GQA로 가는 어텐션 압축 경로
- 여기서 Llama 직계, Mistral, Cohere라는 세 갈래가 생김



세대	출시	어텐션	비고
Llama 1	2023-02	MHA	RMSNorm · SwiGLU · RoPE 표준 정립
Llama 2	2023-07	GQA(70B만)	GQA의 본격 도입
Llama 3	2024-04	모든 크기 GQA	토큰나이저 · 데이터 확장
Llama 3.1	2024-07	GQA	RoPE 주파수 즉석 계산, paged-decode

직계 후손: Yi · Vicuna · TinyLlama · ExaOne 3.0 · Hunyuan v1 Dense · StableLM 등

- 2023-09 **Mistral 7B**: Sliding Window Attention(SWA) + GQA를 한꺼번에 보급
- 슬라이딩 윈도우는 글로벌 어텐션의 $O(N^2)$ 비용을 일부 피한 첫 실용 해법
- 2024-12 **Ministral 3**: 작은 모델에 Llama-4 스타일 어텐션 스케일링을 엮음
- 2025 **Mistral 3**: Pixtral VLM의 텍스트 백본으로 사용
- 2025 **Mistral 4**: MLA(DeepSeek 영향) + MoE + Llama-4 스케일링이 한데 모인 흐름 5 · 7 · 8의 합류점


- 2024-03 **Command R**: Llama 흐름에서 크게 갈라져 나온 초기 분기
- **Parallel Block**: Attention과 MLP를 *순차가 아니라 병렬로* 계산
 - `out = attn(norm(x)) + mlp(norm(x)) + x`
- **QK Norm**: 내적 전 Q · K에 LayerNorm. Qwen 3 · OLMo2 · SmolLM3 · MiniMax M2로 확산
- **Logit Scaling**: 출력 투영 전 스칼라를 곱함. Gemma · MiniCPM · Llama 4 변형으로 확산
- 2024-12 **Cohere2**: 슬라이딩 패턴(N개 중 1개만 글로벌)으로 Gemma 3 · OLMo3과 같은 길로 수렴

Google은 Llama 템플릿을 그대로 따르기보다, 훈련 안정성을 높이는 구조 변경을 *세대마다* 시도

- 모든 세대 공통: RMSNorm에 `1.0 + weight` 오프셋 적용 (0 나눗셈 방지)
- 세대별 추가 변형:
 - G1 (2024-02): 임베딩 $\times \sqrt{d}$, GeLU
 - G2 (2024-06): Logit softcapping, residual path norm
 - G3 (2025-03): Hybrid attention, Dual RoPE, 블록당 4 norm
 - G3n (2025-05): AltUp · LAUREL · KV 공유 · Per-Layer Inputs
 - G4 26B A4B (2026-04): Top-8/128 전문가 Sparse MoE · Dual Head Dim · Partial RoPE · MTP drafter

Gemma stability variants

Each generation changes the normalization / attention / cache recipe



Main theme: keep Llama compatibility, move stability work into block internals

Gemma 1 (2024-02)

- `RMSNorm(1+w)`: 가중치가 0 근처일 때 그래디언트가 더 안정적
- 임베딩 $\times \sqrt{(\text{hidden_size})}$: 작은 d에서도 스케일을 일관되게 유지
- GeLU 선택. SwiGLU 흐름에서 잠시 벗어난 선택

Gemma 2 (2024-06)

- **Logit softcapping**: Attention 점수와 최종 logit에 `tanh`, 훈련 안정성 향상
- **Residual path norm**: `h = x + norm(layer(x))`, layer 출력에 norm을 적용한 뒤 residual add
- **Alternating attention**: 슬라이딩과 글로벌을 교대로 적용. G3 · Cohere2 · OLMo3 · ExaOne 4로 이어지는 출발점

Gemma 3 (2025-03)

- 블록당 4개 norm + QK Normalization
- Dual RoPE: 로컬 · 글로벌 레이어에 *다른* base frequency
- AnyKVCache: 가변 길이 KV와 고정 길이 Rotating 캐시를 혼합
- Residual Clipping: FP16 범위로 명시 클리핑

Gemma 3n (2025-05)

- AltUp · LAUREL: 레이어 단위 라우팅 · 추가 residual path
- KV Sharing: 형제 레이어 K/V 재사용 → Gemma 4 · LongcatFlash로 확산

Gemma 4 (2026-04)

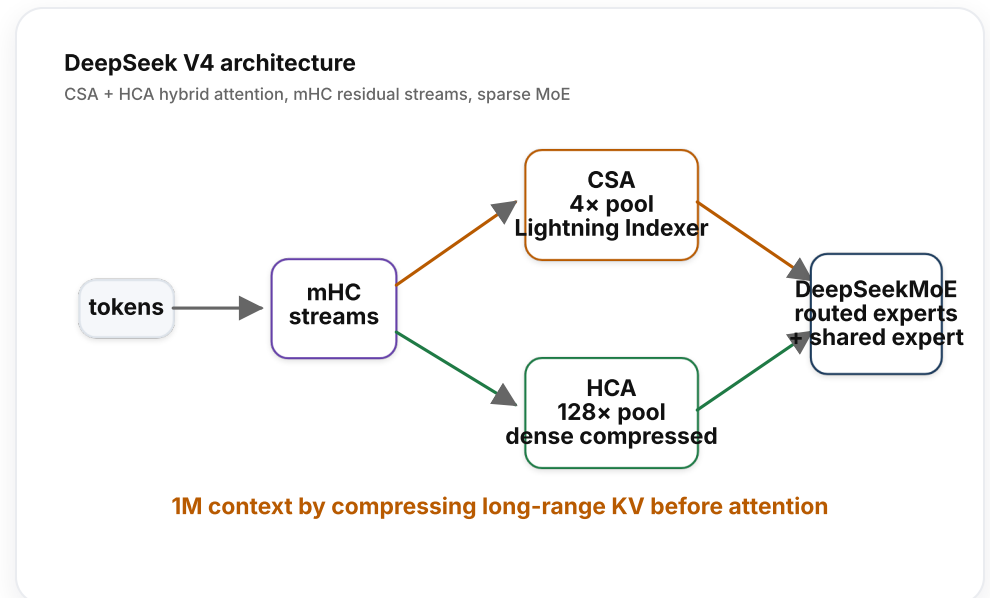
- 26B A4B MoE: 총 26B 중 약 3.8B 활성화, 128 전문가 중 Top-8 라우팅
- Dual Head Dim · Partial RoPE · Per-Layer Inputs
- MTP drafter: 별도 assistant 모델이 후보 토큰을 만들고, 대상 모델이 병렬 검증

모델	시기	핵심
Qwen 2 / 2.5	2024-06 / 09	Attn bias · tied embeddings
Qwen 3	2024-12	QK Norm · MoE 실험 통합
OLMo / OLMo2 / OLMo3	2024-02 → 2025-04	파라미터 없는 LN → Post-norm → SWA
Phi 1 / 2	2023-06 / 12	Partial RoPE, Parallel Block
Phi-3 Mini/Medium	2024-04	LongRoPE (SuScaledRoPE), 128k 문맥
Phi-3 Small	2024-05	Block Sparse + GeGELU + MUP
SmolLM3 (HF)	2025-04	QK Norm + 컴팩트
ExaOne 3.0 (LG)	2024-08	한 · 영 이중언어 + SwiGLU

모델	시기	핵심
StarCoder2	2024-02	모든 선형에 bias, LayerNorm
InternLM 2 / 3	2024-01 / 2025-01	Dynamic NTK RoPE · Packed QKV
GLM-4	2024-01	Post-Norm 하이브리드 · 융합 gate_up_proj
Baichuan / M1	2023-09 / 2024-09	중 · 영 + SWA
MiniCPM / MiniCPM3	2024-04 / 09	depth-scaled residual → MLA + SuScaledRoPE
Hunyuan v1 Dense	2025-03	Tencent 계열 · Llama + SWA
ERNIE 4.5	2025-05	Multi-RoPE · 융합 QKV
HyperCLOVA X SEED (NAVER)	2025-04 → 2026-01	한국어 중심 Dense · VLM · Omni, Peri-LN · μ P

추론 비용을 크게 늘리지 않고 모델 용량을 키우려는 흐름이 여기로 모임

- 2023-12 **Mixtral 8×7B**: 오픈 웨이트 Sparse MoE의 출발점 (Top-K Gating)
- 2024-05 **DeepSeek V2**: **MLA** (KV 압축) + **DeepSeekMoE** (Aux-free 로드 밸런싱) 이 함께 등장
- 2024-12 **DeepSeek V3**: V2를 다듬고 FP8 학습까지 적용. 후속 모델에 가장 큰 영향을 줌
- 2025-01 **DeepSeek R1**: V3 구조에 RL을 엮은 추론(Reasoning) 모델
- 2025-06 **DeepSeek V3.2**: 희소 어텐션용 Indexer + LoRA 스타일 어텐션
- 2026-04 **DeepSeek V4**: CSA/HCA 하이브리드 어텐션 + mHC + 1M context
- 2026-04 **Gemma 4 26B A4B**: 128 전문가 중 Top-8 라우팅으로 약 3.8B만 활성화하는 MoE
- 2024-06+ **Qwen MoE**: 공유 전문가 패턴을 정립했고, 이후 Solar · GLM4 MoE 등으로 전파



모델	시기	라우팅	특징
Mixtral 8×7B	2023-12	Top-K Softmax	표준 출발점
Qwen 2/3 MoE	2024-06 / 12	+ 공유 전문가	norm_topk_prob (Q3 MoE)
PhiMoE	2024-08	Top-K + SuScaledRoPE	긴 문맥 MoE
OLMoE	2024-09	SwitchGLU	Q/K Norm + 정규화
DeepSeek V3	2024-12	Sigmoid + Aux-free	그룹 제한 + e_score 편향
DeepSeek V4	2026-04	SqrtSoftplus + Aux-free	CSA/HCA + mHC + 1M context
Gemma 4 26B A4B	2026-04	Top-8 / 128 전문가	26B 총량 · 약 3.8B 활성 · 256K
ExaOne MoE (LG)	2025	Sigmoid + 그룹	공유 + 라우티드
GLM4 MoE / Lite / DSA	2025	Sigmoid + 그룹	MLA(Lite), Indexer(DSA)
Solar Open 102B-A12B (Upstage)	2026-01	128 라우티드 + 1 공유 전문가	한국어 MoE
Hunyuan MoE	2025-04	Top-K + 공유	tiktoken
ERNIE 4.5 MoE	2025-05	Top-K + 공유	Multi-RoPE 상속
MiMo	2025-06	Top-K + 공유	다중 토큰 예측
MiniMax M2	2025-10	Sigmoid (DSv3)	256 전문가 + QK RMSNorm
GPT-OSS (OpenAI)	2025-08	SwitchGLU + Sinks	MXFP4, 슬라이딩 + Attn Sinks

Attention의 $O(N^2)$ 비용 문제가 RNN · SSM의 부활을 끌어낸 흐름


Mamba 1 (2023-12) / Mamba 2 (2024-05)

- Self-Attention을 1D conv + 순환 상태 업데이트 형태로 대체
- 시퀀스 길이와 무관한 고정 메모리
- Mamba 2: 'Heads'(`n_groups`) 도입, 행렬 곱 유닛 최적화. Falcon Mamba · Mamba-Codestral도 같은 경로

RWKV v7 (2025-01)

- Receptance Weighted Key Value (RNN 패밀리)
- **Token Shift**: 현재 임베딩과 이전 임베딩 혼합
- **WKV Kernel**: 효율적 순환 상태 업데이트용 커스텀 커널
- **Internal LoRA**: 레이어 안에서 광범위한 저랭크 적응

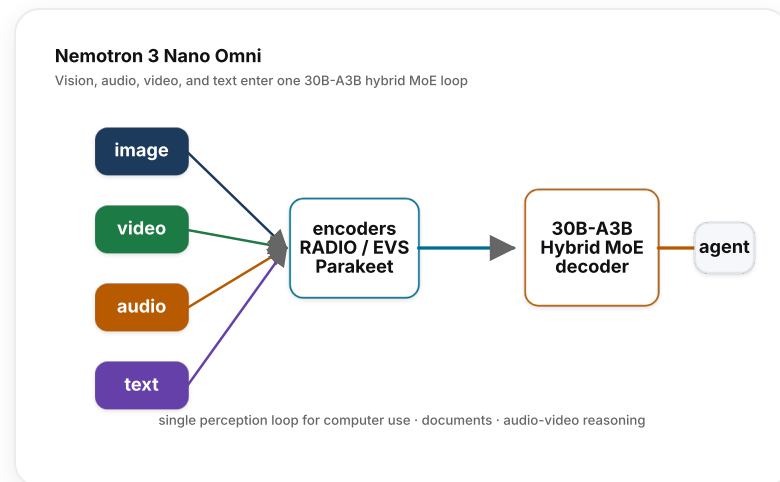
서로 다른 패러다임(Attention + SSM/Linear)을 한 모델 안에 결합



모델	시기	결합
Jamba (AI21)	2024-03	Mamba 레이어와 Attention 교대 + Sparse MoE
RecurrentGemma (Griffin)	2024-04	RGLRU 순환 + 슬라이딩 로컬 attn
Nemotron-H (NVIDIA)	2025-04	Mamba2 + Attn + MLP (+ MoE) 패턴 문자열
Nemotron 3 Nano	2025-12	Hybrid Mamba-Transformer MoE, 30B-A3B 계열
Nemotron 3 Nano Omni	2026-04	30B-A3B Hybrid MoE + image/video/audio encoders
Nemotron-NAS (NVIDIA)	2025-06	NAS로 도출된 이중 레이어 config
Qwen3 Next	2025-06	Full Attn + GatedDeltaNet(Linear) + MoE
Qwen 3.5	2026-02	Qwen3 Next 계승 VLM + GatedDeltaNet/Attention + MoE
Qwen 3.6	2026-04	35B-A3B MoE / 27B Dense, agentic coding 강화 + 내장 MTP

KV 캐시 변화와 여러 패러다임의 융합이 한꺼번에 일어나는 중

- 2025-04 **Llama 4: ChunkedKVCache** + Interleaved MoE + 비전 모델 (Llama 4 Scout)
- 2026-04 **DeepSeek V4**: CSA/HCA 압축 어텐션 + mHC + hash-MoE bootstrap
- 2026-02/04 **Qwen 3.5/3.6**: Qwen3 Next 계승, 네이티브 VLM + GatedDeltaNet/Attention + MoE/Dense + 내장 MTP
- 2025-07 **ExaOne 4 (LG)**: 'LLLG' 슬라이딩 패턴 + Output-norm + Q/K RMSNorm
- 2025-08 **GPT-OSS (OpenAI)**: Sparse MoE + 슬라이딩/풀 어텐션 교대 + **Per-head Attention Sinks** + MXFP4
- 2025-08 **LongcatFlash (Meituan)**: MLA + 듀얼 서브레이어 디코더 (레이어당 2× attn + 2× MLP) + 선택적 n-gram
- 2025-07 **Kimi K2 (Moonshot)**: KimiMLAAttention과 KimiDeltaAttention(GatedDeltaNet)을 교대 배치 + DeepSeek MoE
- 2025-09 **Step 3.5 (StepFun)**: ZeroCenteredRMSNorm + 헤드별 게이트 + 레이어별 RoPE
- 2026-01 **HyperCLOVA X SEED Omni/Think**: 8B Omni는 텍스트·이미지·비디오·오디오 입출력을 통합, 32B Think는 128K VLM 추론 + thinking mode 제공
- 2026-04 **Nemotron 3 Nano Omni**: 텍스트·이미지·비디오·오디오를 한 30B-A3B Hybrid MoE 루프로 통합



Part 2

알고리즘 변화, 주제별로 살펴보기


Thread	주요 갈래
Normalization	LayerNorm → RMSNorm → +1 → Post-norm → QK Norm → 4-norm → Gated → ZC
Attention	MHA → MQA → GQA → SWA → MLA → Block Sparse → Sinks → Chunked
Positional	RoPE → Partial → LongRoPE / YaRN / NTK → Multi/Dual/Per-layer
Activation	ReLU → GeLU → SwiGLU → GeGLU → Clamped SwiGLU → ReLU ²
MoE	Top-K → 공유 전문가 → Aux-free → Sigmoid → 거대/세분화 전문가
KV Cache	KVCache → Rotating → Chunked → CacheList → 혼합 (KV + Mamba)
Non-Attention	SSM → RNN → Linear Attention → Hybrid
Decoding	Speculative decoding → 외부 drafter → 내장 MTP → 병렬 검증

- LLM은 수십~수백 레이어까지 깊게 쌓이는 구조
- 깊이가 깊을수록 residual stream에서 활성화값 분산이 커지기 쉬움
- 정규화는 수치 안정성뿐 아니라 학습 가능 여부 자체를 좌우
- LLM 진화의 큰 줄거리 중 하나는 'Norm을 어디에, 몇 개, 어떻게 끼울까'라는 질문

- 기존 **LayerNorm**: 평균과 분산을 모두 계산. reduction 두 번 필요
- **RMSNorm**: 평균 0을 가정하고 *RMS*만 계산. reduction 한 번이면 충분
 - $y = x / \sqrt{\text{mean}(x^2) + \epsilon} \cdot \gamma$
- 효과: 같은 품질에서 forward가 ~10-15% 더 빠르고, 메모리는 비슷함
- Llama 10이 표준화한 후 거의 모든 후속 모델이 채택
- 예외 분기: Cohere · Phi · OLMo · StarCoder2 · StableLM은 LayerNorm 유지

LayerNorm vs RMSNorm



Removing the mean subtraction saves one reduction




- **Pre-norm** (대다수): $h = x + \text{layer}(\text{norm}(x))$, Llama 패밀리 전부
- **Post-norm** 회귀: 깊은 네트워크의 그래디언트 흐름 개선이 목적
 - **GLM-4** (2024-01): pre-norm + attn/mlp 뒤에도 norm 추가 ('Post-norm 하이브리드')
 - **OLMo2** (2024-11): Q/K norm 추가 후 본격 post-norm 전환
 - **Gemma 2** (2024-06): Residual path norm $h = x + \text{norm}(\text{layer}(x))$, residual add 전 정규화
 - **HyperCLOVA X SEED Think** (2025-07): Peri-Layer Normalization, 서브레이어 출력 뒤 RMSNorm 추가 + μP 스케일링
- 매우 깊은 MoE(80+ 레이어)에서는 post-norm 계열이 안정적이라는 공감대가 생기는 중

Pre-norm vs Post-norm

Where the normalization sits relative to the residual addition

Pre-norm: $x + \text{layer}(\text{norm}(x))$ Post-norm family: $x + \text{norm}(\text{layer}(x))$ 


- 내적 계산 전 Q와 K에 별도 norm을 적용
- 효과: 큰 모델의 학습을 안정화하고, 어텐션 폭주를 억제
- **Cohere** (2024-03) 최초 (LayerNorm2D)
- 1년 안에 Qwen 3 / Qwen 3 MoE(RMSNorm) · OLMo2 / OLMo3 · Gemma 3 · ExaOne 4 · SmolLM3 · InternLM3 · MiniMax M2 · ExaOne MoE로 확산
- 2024-2025년 신모델에서는 기본 선택지에 가까워진 상태



- 블록당 norm이 **4개** (Input · Post-Attn · Pre-FFN · Post-FFN), 여기에 Q · K norm 2개가 더 붙음
- 한 레이어 = 6개 RMSNorm 호출
- Residual Clipping까지 추가 (FP16 범위 강제)
- 비용: 추론 시 norm 호출은 늘지만 메모리 대역폭에 비례하고, 병목은 아님
- 트레이드오프: 학습 안정성은 좋아지지만 추론 지연이 살짝 늘어남

Gemma 3: many norms in one block

Input / attention / FFN paths all get their own normalization


**6 RMSNorm calls per layer**

- **RMSNormGated** (Qwen3 Next): 출력에 `silu(gate)` 곱
 - Linear Attention 결과를 정규화하면서 *동시에* 게이트
- **MambaRMSNormGated** (Nemotron-H): Mamba 블록 출력 정규화 + 게이트
- **ZeroCenteredRMSNorm** (Step 3.5): 런타임 동작은 RMSNorm과 같고, 학습 안정성을 보강
- **NemotronLayerNorm1P** (Nemotron-4): `weight + 1` 오프셋 (Gemma와 같은 패턴)

Gated / centered normalization variants

Normalize the state, then modulate how much passes through

Qwen3 Next / Nemotron-H: gate controls normalized state



어텐션은 메모리(KV 캐시)와 연산량($O(N^2)$)을 동시에 잡아먹는 부품

네 가지 접근


- 압축: MHA → GQA, 헤드가 K/V를 공유해 캐시를 줄임
- 우회: SWA · MLA, 전체 KV를 직접 들고 가지 않는 경로
- 희소화: CSA/HCA, 중요한 토큰과 해시 버킷 중심으로 선택
- 대체: SSM · Linear, 어텐션을 순환 상태나 선형 연산으로 치환

흐름 1-5의 큰 변화는 대부분 어텐션 주변에서 일어남. DeepSeek V4부터는 MLA 이후 단계인 CSA/HCA까지 진입

- **MHA** (Multi-Head): 헤드마다 K/V가 독립적. KV 캐시 = $H \times d_k \times L \times N$
- **MQA** (Multi-Query): 모든 헤드가 *같은* K/V를 사용. 캐시는 $1/H$ 로 줄지만, 품질 손실이 약간 있음
- **GQA** (Grouped Query): 헤드를 그룹으로 묶어 그룹당 K/V를 공유. MHA와 MQA 사이의 *타협점*
- **확산 경로**
 - Llama 2 70B (2023-07) 첫 도입 → Llama 3 전 사이즈 적용
 - Mistral 7B와 동시기에 표준화
 - 2024년 이후 GQA는 *기본값*에 가까움. 새 모델이 MHA를 쓰면 그 이유가 따로 있어야 함


MHA → MQA → GQA

Different ways to share K/V heads



KV cache size shrinks as K/V sharing increases


- 토큰이 자기 앞 W개만 봄. 어텐션이 국소화/되는 구조
- 효과: $O(N^2) \rightarrow O(N \cdot W)$ 연산, RotatingKVCache로 캐시도 W로 고정
- **Mistral 7B** (2023-09) 도입 후 거의 모든 후속 모델에서 옵션화
- 단점: 멀리 떨어진 토큰을 직접 못 봄
- 보완 패턴은 대부분 SWA, 일부 레이어만 글로벌로 두는 **Alternating Attention**
 - Gemma 2 $\rightarrow$ Gemma 3 (로컬 · 글로벌 교대)
 - Cohere2 (N개 중 1개만 글로벌)
 - OLMo3 (post-norm + SWA)
 - ExaOne 4 (LLLG 같은 패턴 문자열로 명시)
 - GPT-OSS (layer_types로 명시)



- DeepSeek V2 (2024-05)가 제안. KV를 저랭크 잠재 벡터로 압축
- 메커니즘: $c_t^{\{KV\}} = W_{DKV} \cdot h_t$ (압축), 디코딩 시 $k = W_{UK} \cdot c$, $v = W_{UV} \cdot c$ (복원)
- 효과: 품질은 유지하면서 KV 캐시 메모리 5-10x↓
- LoRA 스타일 분해로 추가 압축 가능 ($q_a_proj \rightarrow q_a_layernorm \rightarrow q_b_proj$)


MLA: latent KV compression

Store a compact latent vector, reconstruct K/V during decode

KV cache stores c , not full K/V**계승 경로**

- DeepSeek V3 / R1 / V3.2 (Indexer 추가)
- DeepSeek V4 (MLA 계열을 CSA/HCA 하이브리드 압축 어텐션으로 대체)
- MiniCPM3 (엣지 LLM에 MLA + SuScaledRoPE)
- GLM4 MoE Lite (LoRA 스타일 KV 압축)
- Mistral 4 (Llama-4 스케일링과 결합)
- Kimi K2 (Linear Attention과 교대)
- LongcatFlash (듀얼 서브레이어와 결합)


- **Block Sparse Attention:** 미리 정의한 블록 마스크로 일부 토큰 쌍만 계산
 - **Phi-3 Small** (2024-05). Dense + Block Mask 혼합
- **Sparse Attention용 Indexer:** Top-k 인덱스를 학습된 보조 어텐션으로 고름
 - **DeepSeek V3.2** (2025-06) 도입, 효율적인 긴 문맥
 - **DeepSeek V4** (2026-04): CSA는 4× 압축 KV 위에서 Lightning Indexer로 top-k 블록 선택, HCA는 128× 압축 KV를 dense로 읽음
 - GLM MoE DSA가 V3.2 Indexer를 GLM 매핑으로 흡수
 - **CacheList:** 메인 어텐션 캐시 + Indexer 캐시 = 레이어당 캐시 2개



- 첫 토큰이 어텐션을 과도하게 흡수해버리는 *attention sink* 현상
- 슬라이딩 윈도우에서 첫 키편위가 멀어지면 학습 때의 분포와 어긋남
- **GPT-OSS** (2025-08): 첫 키편위에 학습된 편향을 추가 (*per-head Attention Sinks*)
- **DeepSeek V4** (2026-04): CSA/HCA 공통 백본에도 per-head learnable sink 사용
- 효과: 슬라이딩 윈도우에서도 어텐션 엔트로피 손실 방지
- 별도 의미 토큰 없이 학습된 편향만으로 안정화


Attention Sinks

Learned per-head bias keeps sliding-window attention stable



prevents first-position distribution shift under SWA

- 기존 KVCache는 *연속 메모리* 할당이라 긴 시퀀스에서 단편화가 생김
- **ChunkedKVCache** (Llama 4, 2025-04): KV를 청크 단위로 저장
 - 메모리 할당 단편화 회피
 - 가변 시퀀스 길이에 더 유연
- Interleaved MoE와 함께 사용: dense 레이어 사이에 MoE를 전략적으로 배치 (예: 매 4번째)
- 동적 attention 스케일링 (`floor_scale`, `attn_scale`)



패턴	모델	핵심
SWA 단독	Mistral 7B, Baichuan M1	처음부터 끝까지 슬라이딩
Alternating (교대)	Gemma 2, Cohere2, OLMo3	일부 글로벌
패턴 문자열	ExaOne 4 (LLLG), GPT-OSS	레이어마다 명시
Dual Cache	Gemma 3, ExaOne 4	로컬은 Rotating, 글로벌은 KVCache
MLA + Linear 교대	Kimi K2	KimiMLAAttention과 KimiDeltaAttention
MLA + 듀얼 서브	LongcatFlash	한 '레이어'가 2× attn + 2× MLP
Full + Linear	Qwen3 Next, Qwen 3.5/3.6	full_attention_interval로 교대

- 절대 위치 → 상대 위치 → 회전 위치(RoPE) 형태로 수렴해 온 역사
- **RoPE의 강점:** 상대 위치 정보를 곱셈으로 주입하면서도 KV 캐시와 잘 맞음
- 2023년 이후 거의 모든 모델이 RoPE 변형 사용
- 세 가지 분기
 - 얼마나 적용할까 (Partial)
 - 어떻게 늘릴까 (Long)
 - 어떻게 섞을까 (Multi/Dual)

- **RoPE** (RoFormer, 2021): Query · Key에 차원별 회전 행렬을 곱함
- 표준은 헤드 차원 *전체*에 적용
- **Partial RoPE**: 헤드 차원의 *일부*에만 적용, 나머지는 그대로
 - Phi 1/2 (2023-06) 첫 도입
 - Phi-3 Mini/Medium
 - GLM-4 (2024-01) 도입
 - Nemotron-4 (2024-06)
 - MiniMax M2(2025) · Gemma 4(2026)까지 확산
- 직관: 일부 차원은 위치의 영향을 덜 받고 의미 정보를 더 담게 됨

RoPE vs Partial RoPE

Which head dimensions receive positional rotation?


Full RoPE

All dimensions of Q/K carry position information.




Partial RoPE

Only selected dimensions rotate; the rest stay as content/semantic dimensions.



- 표준 RoPE는 학습 길이를 벗어나면 *외삽에 실패*하기 쉬움
- 세 갈래의 확장 기법이 거의 동시에 등장




기법	출처	특징
LongRoPE (SuScaledRoPE)	Phi-3 (2024-04)	짧은/긴 길이마다 별도 스케일링. 소형 모델이 128k 지원
YaRN	DeepSeek V2 (2024-05)	NTK-aware + 점진 보정. 가장 널리 채택
Dynamic NTK	InternLM2 (2024-01)	추론 시 가변 길이에 적응, 외삽 우수

채택 분포: Phi-3 / PhiMoE(LongRoPE), DeepSeek 전 세대 / Mistral 4 / GPT-OSS(YaRN), InternLM2/3(Dynamic NTK) 정도

- **Multi-RoPE** (ERNIE 4.5, 2025-05): 헤드 차원의 *다른* 부분에 *다른 RoPE* 설정 적용
 - `multi_rope_section` · `multi_rope_factor`
- **Dual RoPE** (Gemma 3, 2025-03): 로컬 · 글로벌 레이어가 *다른* base frequency
- **Per-layer RoPE** (Step 3.5, 2025-09): 레이어마다 `rope_theta` 와 `partial_rotary_factor` 가 다름
- **M-RoPE** (Qwen2-VL): 2D/3D 위치 정보. 비전 토큰 좌표를 RoPE에 직접 인코딩
- **No RoPE on global** (Cohere2, ExaOne 4): 글로벌 레이어에서는 RoPE를 ~~배~~는 선택

Multi / Dual / Per-layer RoPE

Different layers or head sections can carry different rotary settings




section-wise / layer-wise position geometry

- 2017 Transformer는 ReLU
- 2019 BERT는 GeLU
- 2022년 GLU 계열 제안 → 2023년 Llama 10이 **SwiGLU** 표준화
- SwiGLU = $\text{Swish}(x \cdot W_{\text{gate}}) \odot (x \cdot W_{\text{up}}) \cdot W_{\text{down}}$
- 효과: ReLU/GeLU 대비 같은 품질까지 더 빠르게 수렴
- 2023년 이후 거의 모든 모델이 SwiGLU 또는 그 변종을 사용

SwiGLU / GLU-family FFN


Gate branch controls the up-projection branch



Swish / GeLU / clamp variants live in the gate path

SwiGLU / GLU-family FFN

Gate branch controls the up-projection branch



Swish / GeLU / clamp variants live in the gate path


변종	모델	특징
표준 SwiGLU	Llama, Mistral, Qwen, DeepSeek 등 다수	$\beta=1$
GeGLU	Gemma 2	Gate에 Swish 대신 GeLU
GeLU approx	Gemma 3 · 3n · 4	빠른 근사 GeLU
GeGELU	Phi-3 Small	명시적 입출력 클램프
Clamped SwiGLU	Step 3.5, GPT-OSS	레이어별 클램프 한계 (<code>swiglu_limit</code>)
Custom α	GPT-OSS	<code>alpha=1.702</code> Swish

큰 흐름은 *클램프* 추가 방향. 학습 안정성과 MoE 전문가 출력 폭주 억제에 효과

- **Squared ReLU** ($\text{relu}(x)^2$): GeLU/SwiGLU 대비 더 날카로운 비선형성
- **Nemotron-4** (2024-06): 엔터프라이즈용 견고성에 초점
- **Nemotron-H** (2025-04): Mamba2 + Attn + MLP/MoE 하이브리드의 MLP에 ReLU² 유지
- 직관: 0 이하는 0, 0 이상은 제곱. sparse한 활성 패턴과 강한 양수 신호를 만듦
- 채택은 NVIDIA 계열에 집중됨. 다른 패밀리는 대체로 SwiGLU 계열 유지

Squared ReLU


Sharper positive response than ReLU / GeLU-style activations



- 모델 용량은 총 *파라미터*로 키우되, *활성 파라미터*는 작게 유지
- 추론 비용은 활성 파라미터에 비례 → 100B 모델도 10B 수준 비용으로 동작
- 단점: 로드 밸런싱과 라우터 학습이 불안정하고, 메모리는 여전히 총 파라미터 크기를 따라감
- 2023-12 Mixtral 이후 *2년 만에* MoE가 큰 모델의 사실상 표준이 된 상태
- 2026년에는 DeepSeek V4-Pro(1.6T/49B active)와 Nemotron 3 Nano(30B-A3B)가 같은 흐름을 서로 다른 방식으로 확장

Sparse MoE routing

A small router chooses a few experts per token




Top-k active experts; inactive experts stay cold

- **Mixtral 8×7B** (2023-12): 8 전문가 × 7B = 46.7B 총, 12.9B 활성화
- **Top-K Gating** (K=2): 라우터가 토큰당 상위 2 전문가를 선택
- **Sparse Block**: MLP를 전문가 MLP 뱅크로 대체
- 학습 안정화는 auxiliary loss로 로드 밸런싱을 맞춤
- 한계: aux loss가 학습 신호와 충돌, 그룹 균형이 미세하게 깨짐. 이후 *Aux-free*로 해결

Sparse MoE routing

A small router chooses a few experts per token




Top-k active experts; inactive experts stay cold

- **Qwen 2 MoE (2024-06):** 라우티드 전문가 *외에*, 모든 토큰에 활성화되는 **공유 전문가** 도입
- 출력은 $\text{MoE_output} + \text{sigmoid}(\text{Gate}) \cdot \text{Shared_Expert_Output}$
- 직관: 공통 지식은 공유 전문가가 맡고, 특화 지식은 라우티드 전문가가 맡음. 라우터 부담도 줄어듦
- 확산: DeepSeekMoE · OLMoE · ExaOne MoE · GLM4 MoE · Hunyuan MoE · ERNIE 4.5 MoE · MiMo · Solar Open · LongcatFlash
- Qwen 3 MoE (2024-12)에서 norm_topk_prob 정규화가 추가됨

Shared expert pattern

Routed experts handle specialization; shared expert handles common knowledge




$\text{MoE_output} + \text{sigmoid}(\text{gate}) \cdot \text{Shared_Expert_Output}$

- DeepSeek V3 (2024-12)가 제안. 보조 손실 없이 부하 균형을 맞춤
- 편향 보정(`e_score_correction_bias`) 사용
 - 각 전문가에 학습 가능한 편향 추가
 - 균형이 깨지면 *편향만* 동적으로 보정하고, 본 라우터 점수는 건드리지 않음
- Group Limited Greedy: 사전 정의된 그룹으로 전문가 선택 제한. 그룹 간 균형 보장
- FP8 학습 지원: V3가 FP8로 학습된 첫 대규모 오픈 모델
- 확산: V3.2 · R1 · Kimi K2 · MiniMax M2 등
- V4에서는 초반 hash-MoE bootstrap + SqrtSoftplus affinity로 변경, Aux-free 편향 보정은 유지

Aux-free load balancing

Adjust expert bias without changing the main router score



- 표준 Top-K MoE는 라우터에 softmax를 사용
- Sigmoid 라우팅**: 각 전문가 점수를 독립적인 $0 \sim 1$ 로 계산. 여러 전문가가 동시에 강한 신호를 낼 수 있음
- 강점: 학습 신호가 한 전문가에 쏠리는 압력 약화
- 채택: **DeepSeek V3 · MiniMax M2 · Solar Open · GLM4 MoE / DSA · Step 3.5 · ExaOne MoE**
- MiniMax M2 (2025-10): **256 전문가** + top-8 + 시그모이드. 현재까지 가장 큰 규모의 사례
- DeepSeek V4는 Sigmoid에서 SqrtSoftplus affinity로 이동. 라우팅 함수 자체도 모델별 최적화 대상


Softmax vs Sigmoid routing

Softmax couples experts; sigmoid scores each expert independently


softmax: sums to 1



sigmoid: independent scores



- LLM 서버의 메모리 압박은 *모델 가중치*보다 *KV 캐시*에서 더 크게 나오는 중
- 긴 컨텍스트에서는 KV가 모델보다 큼
- 이제 캐시 구조 자체가 모델 설계의 결정 요소가 됨




캐시	등장	용도
KVCache (표준)	2023~	풀 어텐션
RotatingKVCache	Mistral SWA (2023-09)	슬라이딩 윈도우 (고정 W 크기)
CacheList	DeepSeek V3.2 (2025-06)	메인 + Indexer 캐시
CSACache / HCACache	DeepSeek V4 (2026-04)	슬라이딩 K=V + 압축 풀 + Indexer 상태
ChunkedKVCache	Llama 4 (2025-04)	청크 단위 할당 (단편화 회피)
AnyKVCache	Gemma 3 (2025-03)	가변 길이 KV + 고정 길이 Rotating 혼합
MambaCache	Mamba (2023-12)	순환 상태 (고정 크기)
혼합 KV + Mamba	Qwen3 Next, Nemotron-H, Nemotron 3 Nano	레이어 종류에 따라 다른 캐시
ArraysCache	LongcatFlash	n-gram 해시 룩업

- Self-Attention의 $O(N^2)$ 비용은 긴 시퀀스에서 *현실적인 한계*가 됨
- 상태 공간 모델인 SSM과 RNN이 동시에 부활
- Nemotron 3 Nano는 Mamba-Transformer MoE로 긴 reasoning trace 처리량을 끌어올린 계열
- Linear Attention은 둘 사이에 걸친 형태로, 어텐션을 *순환 상태*로 표현

- **State Space Model:** 연속 시간 시스템 $h'(t) = A \cdot h(t) + B \cdot x(t)$ 를 이산화
- 핵심 트릭은 A 를 입력에 따라 달라지는 **선택적** 행렬로 만들어, 입력에 맞춰 **기억** 정도를 조절하는 것
- **Mamba 1** (2023-12): Selective SSM + Hardware-aware Parallel Scan
- **Mamba 2** (2024-05): 'Heads'(`n_groups`) 도입, 행렬 곱 유닛으로 재해석
- **Nemotron 3 Nano** (2025-12): Mamba-2 레이어를 Transformer/MoE와 섞은 30B-A3B Hybrid MoE
- RNN처럼 메모리 크기는 시퀀스 길이와 무관한 **고정 크기**
- 한계: 정확한 회상(retrieval)이 어려움. Hybrid가 등장한 배경

Mamba selective SSM

Input-dependent state update with fixed memory




parallel scan computes recurrent updates efficiently

- Receptance Weighted Key Value. Linear Attention과 RNN의 교집합
- **Token Shift:** 현재 임베딩을 이전 임베딩과 혼합 (x_r , x_k , x_v , x_g)
- **WKV Kernel:** 효율적인 순환 상태 업데이트를 위한 커스텀 커널
- **Internal LoRA:** 레이어 정의 *안쪽*에서 저랭크 적응을 수행
- **강점:** 추론 시 *진짜* $O(1)$ 메모리와 *진짜* 스트리밍

RWKV token shift + WKV state


Mix current token with previous token, then update recurrent WKV state



- 정확한 회상(어텐션)과 긴 컨텍스트(SSM/Linear)를 *한 모델에서* 결합
- **Qwen3 Next (2025-06)**: GatedDeltaNet 레이어와 Full Attention을 `full_attention_interval`로 교대
- **GatedDeltaNet 메커니즘**: $g = \exp(-\exp(A_{\log}) \cdot \text{softplus}(a + dt_bias))$, 학습된 게이트로 상태를 업데이트
- **Qwen 3.5 (2026-02)**: Qwen3 Next 계승 네이티브 VLM, Gated DeltaNet + Gated Attention + sparse MoE
- **Qwen 3.6 (2026-04)**: 같은 계열을 35B-A3B MoE와 27B Dense 오픈 모델로 확장, 내장 MTP까지 포함
- **Kimi Linear / K2 (2025)**: KimiMLAAttention과 KimiDeltaAttention 교대 (MLA + Linear 결합)
- **혼합 캐시**: Linear 레이어는 MambaCache, Full 레이어는 KVCache 사용


Full Attention + Linear Attention hybrid

Alternate exact recall layers with long-context recurrent layers



full_attention_interval controls the cadence

- **Speculative decoding:** 작은 drafter가 여러 토큰을 먼저 제안, 큰 target 모델이 한 번에 검증
- 거절된 토큰이 있어도 target이 그 위치의 정답 토큰을 내므로, 출력 품질은 target 모델 기준으로 유지
- **MTP:** DeepSeek V3의 보조 학습 목표에서 시작해, 2026년에는 서빙 기능으로 전면화
- **Qwen 3.6:** 체크포인트에 `mtp.*` 가중치 포함. vLLM `qwen3_next_mtp`, SGLang `NEXTN` 경로로 사용
- **Gemma 4:** `*-assistant` 4-layer drafter를 별도 공개. 26B A4B는 MoE라 배치 1에서 expert reuse가 낮으면 이득이 줄 수 있음



Part 3


종합과 시사점

1. **효율성:** MoE가 본격화되고(DeepSeek V3/V3.2/V4 · Mixtral · MiniMax M2 · GPT-OSS · Nemotron 3 Nano), Linear Attention 비중도 커짐(Mamba · RWKV · Qwen3 Next · Qwen 3.5/3.6 · Kimi Linear)
2. **안정성:** 정규화가 복잡해짐 (Gemma 2/3 다중 norm, QK Norm 확산, RMSNormGated, ZeroCenteredRMSNorm)
3. **전문화:** 엣지(MiniCPM · Phi-3 · SmolLM3), 도메인(StarCoder2 코드, R1 추론), 지역(ExaOne · HyperCLOVA · Solar · Baichuan · Hunyuan · ERNIE · Kimi)으로 세분화
4. **하이브리드화:** Transformer와 SSM/Linear를 함께 사용(Jamba · RecurrentGemma · Nemotron-H/Nano · Qwen3 Next · Qwen 3.5/3.6 · Kimi K2 · LongcatFlash)
5. **캐시 구조 변화:** CacheList · DeepSeek V4 CSA/HCA 캐시 · ChunkedKV · 혼합 KV+Mamba · Rotating

- **Llama** → 거의 전부 (RMSNorm · SwiGLU · RoPE · GQA)
- **Mistral** → SWA를 여러 후속 모델로 확산
- **Cohere** → QK Norm을 1년 안에 8개 이상 모델로 확산
- **Mixtral** → Top-K MoE의 표준 출발점
- **Gemma 2** → Alternating attention, Logit softcapping, residual norm
- **DeepSeek V2/V3/V4** → MLA + Aux-free에서 CSA/HCA + mHC까지 이어지며 긴 문맥 MoE의 기준선을 계속 이동
- **Mamba / Nemotron** → 단독 SSM 모델 수는 적어도, Hybrid Mamba-Transformer MoE의 기반
- **Qwen MoE** → 공유 전문가 패턴을 거의 모든 후속 MoE로 확산

영역	과제
라우팅 로직	Softmax / Sigmoid / SqrtSoftplus, 그룹/공유 전문가, Aux-free 편향 보정
상태 관리	SSM/RNN/Linear Attention의 <i>순환 상태</i> , DeepSeek V4 CSA/HCA 압축 상태
어텐션 마스크	슬라이딩 / Alternating / 패턴 문자열 / Block Sparse / Attention Sinks
다중 캐시	CacheList/CSACache/HCACache, 혼합 KV+Mamba, RotatingKV, ChunkedKV
추측 디코딩	MTP head/assistant, draft token 스케줄, acceptance rate, assistant KV 공유
양자화	FP8 PTQ (Qwen3.6 · Nemotron), NVFP4 (Gemma 4 PTQ · Nemotron QAD), MXFP4 (GPT-OSS)
비전 백본	M-RoPE, MSFA, 동적 소프트 토큰, Nemotron Omni CRADIO/Parakeet 인코더

단순 GEMM 최적화만으로는 부족. 모델 구조 자체가 서빙 코드의 형태를 결정



- **ExaOne 3.0/4.0** (LG, 2024-2025): Llama 계열에서 출발, 'LLLG' 패턴 + Output-norm + Q/K RMSNorm으로 신표준에 합류
- **ExaOne MoE** (LG, 2025): Sigmoid + 그룹 + 공유. DeepSeek 흐름을 흡수
- **HyperCLOVA X SEED** (NAVER, 2025-04~): 0.5B/1.5B Text, 3B Vision, 14B/32B Think, 8B Omni로 공개 라인업 확장
- **SEED Think/Omni** (2025-07~2026-01): Peri-LN + μ P 기반 reasoning, 32B VLM 128K, 8B any-to-any 한국어 우선 Omni
- **Solar Open 102B-A12B** (Upstage, 2026-01): 128 라우티드 + 1 공유 전문가 MoE
- 국내 모델은 새로운 분기라기보다 *합류와 한국어 특화에 가까움*. 세계 흐름을 빠르게 흡수해 공개 생태계를 키우는 패턴

- 단일 패러다임의 종료: 흐름 8 신모델 대부분이 **복합** 구조
- 캐시 · 라우팅 다양성 확대: 레이어마다 다른 어텐션, 캐시, RoPE 조합
- 양자화 친화적 배포: Qwen3.6 · Nemotron 3 Nano는 BF16 기반 FP8 PTQ, Gemma 4는 BF16 기본 + NVFP4/FP8 PTQ. Nemotron Nano NVFP4는 QAD로 보정
- **MTP/Speculative decoding** 전면화: Qwen 3.6은 내장 MTP, Gemma 4는 assistant drafter로 같은 병목을 겨냥
- **Linear Attention** 비중 확대: Qwen3 Next · Qwen 3.5/3.6 · Kimi Linear · LongcatFlash가 후속 모델을 이끄는 흐름
- 서빙 인프라의 자연: 모델 구조 변화보다 늦게 따라오는 실행 · 캐시 · 라우팅 지원, 래블업의 과제



감사합니다.

LLM internals
신정규 · 래블업

- 1차 기준: mlxcel 모델 아키텍처 분석 (Lablup 내부 문서, 2026)
- 공개 자료 우선순위: 공식 기술 보고서 → 모델 카드 → 구현 문서 → 릴리스 노트
- 검증 대상: `config.json`, `generation_config.json`, safetensors index, 공개 체크포인트의 모델 카드
- 구현 확인: Hugging Face Transformers, vLLM, SGLang, MLX-LM/MLX-VLM 구현을 함께 대조
- 표기 방식: 슬라이드 본문은 모델 계보 중심, 레퍼런스는 논문·모델 카드·구현 문서를 분리해 정리

- **Transformer 계열:** Vaswani et al., 2017; **Llama** / **Llama 2**, Meta, 2023; Llama 3/4 모델 카드, Meta, 2024–2026
- **정규화 · 활성화 · 위치 인코딩:** **RMSNorm**, Zhang & Sennrich, 2019; **GLU Variants Improve Transformer**, Shazeer, 2020; **RoFormer/RoPE**, Su et al., 2021
- **어텐션 효율화:** **Mistral 7B**, Jiang et al., 2023; **GQA**, Ainslie et al., 2023; DeepSeek V2의 MLA, DeepSeek-AI, 2024
- **MoE 계열:** Shazeer et al., 2017/2019; **Switch Transformer**, Fedus et al., 2021; **Mixtral**, Jiang et al., 2024; DeepSeek V3/V4 Aux-free · CSA/HCA
- **SSM · RNN · Linear Attention:** **Mamba**, Gu & Dao, 2023; Mamba-2, Dao & Gu, 2024; RWKV v7, Peng et al., 2025; Kimi Linear, Moonshot AI, 2025
- **디코딩:** **Speculative decoding**, Leviathan et al., 2023; **DeepSeek V3**, DeepSeek-AI, 2024; Qwen3.6/Gemma 4 MTP 문서, 2026

- **Llama · Mistral · Gemma:** Meta Llama 1/2/3/4 기술 보고서·모델 카드; Mistral 7B/Mixtral/Mistral 패밀리 모델 카드; Google Gemma 1/2/3/3n/4 기술 보고서·모델 카드
- **Qwen:** Qwen 2/2.5/3, Qwen3 Next, Qwen 3.5, **Qwen3.6-35B-A3B**, Qwen3.6-27B 모델 카드, Alibaba/Qwen Team, 2024–2026
- **DeepSeek:** DeepSeek V2/V3/R1 기술 보고서; **DeepSeek-V4 Transformers 문서**와 공개 모델 카드, DeepSeek-AI, 2024–2026
- **NVIDIA:** Nemotron-H, **Nemotron 3 Nano**, Nemotron QAD/NVFP4, **Nemotron 3 Nano Omni**, NVIDIA, 2025–2026
- **한국 · 지역 모델:** ExaOne 3.0/4.0/MoE, LG AI Research, 2024–2025; **HyperCLOVA X / SEED model cards**, NAVER, 2025–2026; **Solar Open**, Upstage, 2026
- **기타 오픈 흐름:** GPT-OSS, OpenAI, 2025; Kimi K2/Linear, Moonshot AI, 2025; LongcatFlash, Meituan, 2025; MiniMax M2, MiniMax, 2025; Step 3.5, StepFun, 2025

- **Transformers 구현 문서:** Llama, Mistral, Gemma, Qwen/Qwen3 Next, DeepSeek V4, HyperCLOVA X, Nemotron, Solar Open 모델 문서·config
- **Speculative/MTP 서빙:** Qwen3.6 모델 카드의 SGLang `NEXTN` · vLLM `qwen3_next_mtp`; Gemma 4 MTP와 Gemma 4 assistant 모델 카드
- **양자화:** Qwen3.6 FP8 PTQ 모델 카드; Gemma 4 BF16 원본과 NVIDIA/커뮤니티 NVFP4·FP8 PTQ 모델 카드; Nemotron QAD/NVFP4; GPT-OSS MXFP4 문서
- **런타임 구현:** vLLM, SGLang, KTransformers, MLX-LM, MLX-VLM, mlxcel 변환·런타임 코드 경로
- **시각화:** 본문 SVG는 공개 논문/모델 카드의 구조 설명을 바탕으로 발표용으로 재구성